

Grupo: Law Learning Machine (LLM)

Equipo: Nicolas Baquero, David Briceño y Jessica Garay

1. Arquitectura del sistema y flujo en LangGraph

A continuación, se describe el flujo planteado, en el sistema se hace uso de LangGraph para desarrollar este grafo:




Figura 1. Grafo diseñado para sistema RAG

- Entrada y clasificación (classify):** Recibe la consulta, identifica si es de opción múltiple, semiabierta o abierta, y detecta si menciona artículos, leyes o sentencias concretas.
- Búsqueda concurrente (bm25_search y vector_search):** Se ejecutan dos búsquedas en paralelo: BM25 para coincidencias exactas de términos y números de artículos/radicados, y búsqueda vectorial para captar el sentido conceptual de la pregunta.
- Fusión y reordenamiento (fuse_and_rerank):** Se toman los mejores 40 resultados de ambas ramas y pasan por un reordenador (cross-encoder). Se aplican reglas de dominio: máxima prioridad a citas expresas, descarte o relegación de normas derogadas y reserva de espacio para sentencias.
- Control de evidencia y abstención:** Se evalúa la calidad del Top-10. Si la evidencia es débil en el primer intento (retry == 0), pasa a reformulate (amplía la consulta con filtros por área) y reintenta la búsqueda. Si la evidencia sigue siendo insuficiente tras el reintento (retry == 1), abstiene formalmente (force_abstain).
- Generación de respuesta (generate_mc, generate_semi, generate_open):** Se envía la consulta al modelo generador con un prompt diseñado según el tipo de pregunta, usando temperatura 0 para máxima fidelidad.

6. **Extracción y verificación de citas (build_citations y prune_and_verify_citations):** Se arman las referencias desde los encabezados de los pasajes usados y se contrastan con un validador oficial. Si una cita no tiene sustento en los pasajes recuperados, se elimina de inmediato.
7. **Validación y salida (fill_fields y build_submission):** Si quedó algún campo obligatorio vacío por la depuración de citas, se completa con la norma principal. Se valida el formato y se guarda la entrega final en salida.JSONL.

2. Selección de Encoder, Decoder y Reranker

El diseño de modelos equilibra la capacidad técnica de cómputo local con la necesidad de interpretar con exactitud el lenguaje jurídico colombiano, donde tanto los conceptos abstractos como los términos textuales son críticos.

Componentes de recuperación y reordenamiento (Encoder)

- **Encoder denso (BAAI/bge-m3):** Modelo multilingüe con excelente desempeño en español. Soporta contextos largos de hasta 8.192 tokens, lo que permite indexar consideraciones extensas y captar similitud semántica cuando el usuario formula preguntas con sus propias palabras.
- **Búsqueda léxica (BM25):** Vital en el entorno jurídico para resolver identificadores exactos (ej. 'artículo 29', 'sentencia C-037'), donde los modelos vectoriales suelen perder especificidad.
- **Reordenador cruzado (BAAI/bge-reranker-v2-m3):** Evalúa la interacción directa entre la pregunta y cada uno de los 40 pasajes candidatos, filtrando falsos positivos antes de enviar el Top-10 al generador.

Configuración de inferencia: Cuantización FP16 nativa en GPU local (con soporte de cuantización INT4 AWQ para mitigación de latencia); ventana de contexto de 4.096 tokens útiles en generación; temperatura 0.0 para determinismo estricto; y un tiempo medio de inferencia de 3.8 a 4.2 segundos por pregunta completa (incluyendo recuperación dual y re-ranking).

3. Estrategia de recuperación

- **Criterio y segmentación:** Artículos normativos extensos (>6.000 caracteres) se fragmentan en bloques de 3.000 caracteres. Las sentencias judiciales se dividen por consideraciones y secciones en ventanas deslizantes de 1.500 caracteres con solape de 200. Cada fragmento lleva inyectado en su encabezado el nombre oficial completo de la norma para mantener contexto semántico.
- **Índices y Top-k:** Se mantienen dos índices independientes: uno de normas (129.102 fragmentos) y uno de jurisprudencia (637.565 fragmentos). La recuperación híbrida densa/léxica extrae un Top-40 consolidado mediante fusión de rangos, que luego es filtrado por el reordenador a un Top-10 final.
- **Cobertura del corpus:** 9.466 documentos oficiales incorporados (SUIN-Juriscol, Senado, Función Pública, Cortes y CAN). Cobertura del 100% de las 10 áreas del banco (542 de 559 ítems con documento objetivo indexado, equivalente al 98%-100% por área).

4. Verificación de citas y abstención

- **Verificación de citas:** El nodo prune_and_verify_citations contrasta cada referencia jurídica generada contra el extractor oficial y la lista de los 10 pasajes recuperados. Si el modelo cita una norma o sentencia que no esté respaldada en la evidencia textual, la cita se purga automáticamente. Si faltan datos obligatorios, fill_fields completa con la norma del pasaje principal.

- Condición de abstención: Se activa abstención forzada (force_abstain) cuando el puntaje de relevancia del mejor pasaje recuperado se sitúa por debajo del umbral crítico tras haber ejecutado una reformulación previa (retry == 1). Esta política aplica únicamente a preguntas abiertas y semiabiertas; en preguntas de selección múltiple el sistema nunca se abstiene.

5. Resultados de muestra, limitaciones y mejoras

Componente evaluado	Puntaje	Posible	% Efectividad
Exactitud en preguntas cerradas	9.46	20.00	47.3%
Calidad de citación	13.88	20.00	69.4%
Abstención calibrada	6.74	10.00	67.4%
Total automático	43.51	50.00	87.0%

Tabla 2. Resultados de muestra

Análisis de los errores más frecuentes:

- Forzado en selección múltiple: La regla de no abstención en preguntas cerradas penaliza la exactitud (9.46/20) cuando el ranking recupera normas relacionadas, pero no la causal específica evaluada, forzando una elección sin certeza probabilística.
- Citas suprimidas por estrictez: El validador oficial descartó citas correctas en casos donde la norma aplicaba como principio general pero no figuraba textualmente en los 10 fragmentos inyectados en contexto.
- Ambigüedad en preguntas semiabiertas: Respuestas que combinan dos artículos complementarios recibieron penalizaciones parciales si la reformulación priorizó solo una de las sub-áreas temáticas.

6. Limitaciones

- **Latencia acumulada y cuello de botella en inferencia:** La ejecución secuencial del doble retrieval (BM25 + BGE-M3), la reordenación profunda de 40 candidatos con cross-encoder y la posterior decodificación autoregresiva en GPU local saturan la memoria de cómputo en ráfagas de consultas.
- **Descontextualización jurisprudencial por segmentación fija:** Las ventanas de 1.500 caracteres resultan insuficientes para abarcar la ratio decidendi completa en sentencias de tutela o constitucionalidad de alta complejidad, separando las premisas jurídicas de la orden resolutive.
- **Sesgo de cobertura por ítems no indexados (17 casos):** Existen 17 ítems huérfanos generados por erratas tipográficas en el banco oficial o resoluciones no publicadas en plataformas públicas abiertas, creando vacíos forzados de respuesta.